

Memoria CodeFest – Valor real de una patente

Diego Sánchez de la Fuente

Contents

1	Introducción: Valor real de una patente	3
1.1	El problema de la valoración en carteras de patentes (ROI de una patente)	3
1.2	Enfoque general del proyecto	3
1.3	Aportación práctica del trabajo	3
1.4	Alcance y limitaciones	4
1.5	Estructura del documento	4
2	Pipeline	4
3	Notebooks	6
3.1	Proxy de ROI robusto (roi_proxy_v3)	6
3.2	Análisis exploratorio de los datos (EDA)	7
3.3	Técnicas de análisis del lenguaje natural (NLP Feature engineering)	10
3.4	Selección de características (variables predictoras):	10
3.5	Dirección del efecto sobre proxy_roi_v3	12
3.6	Entrenamiento de modelo robustos:	12
3.7	Regularización L2 por presupuesto de cambio del modelo finalista:	13
4	API_modelo_ROI – H7 Heptagon Gestor de ciclo de vida del modelo:	17
4.1	Marco H7 – Heptagon	17
4.2	Gestión del modelo	17
4.3	Exposición REST	17
5	Epo_client_web Cliente web inferencia modelo:	18
5.1	Descripción general	18
5.2	Propósito dentro del proyecto	20
5.3	Arquitectura funcional	20
5.4	Requisitos de ejecución	22
5.5	Puesta en marcha	22
5.6	Contribución al framework H7	22

1 Introducción: Valor real de una patente

Este proyecto, presentado al EPO CodeFest 2026, parte de una idea fundamental: una patente es un activo, pero su valor real no es directamente observable. En la práctica, la valoración se construye a partir de señales indirectas de naturaleza técnica, legal, organizativa y temporal. Estas señales suelen analizarse de forma experta, pero de manera poco sistemática y difícilmente reproducible cuando se trabaja con carteras amplias.

El objetivo de este trabajo es proponer un marco analítico reproducible que permita evaluar y priorizar patentes dentro de una cartera. El enfoque no pretende sustituir el criterio experto, sino reforzarlo mediante un análisis basado en datos que sea consistente, explicable y trazable. La finalidad última es facilitar la toma de decisiones estratégicas apoyadas en evidencias observables.

1.1 El problema de la valoración en carteras de patentes (ROI de una patente)

En la gestión de carteras de patentes aparecen decisiones recurrentes relacionadas con el mantenimiento, la extensión internacional, la defensa jurídica o la explotación de los activos. Estas decisiones suelen tomarse bajo restricciones presupuestarias y con información incompleta, lo que incrementa el riesgo de ineficiencias.

El principal reto es que el valor de una patente es un fenómeno multidimensional. Puede reflejar complejidad tecnológica, ambición estratégica, inversión acumulada, persistencia legal o potencial de retorno económico. Además, el valor suele distribuirse de forma muy desigual dentro de una cartera, concentrándose en un número reducido de activos. Sin una forma sistemática de ordenar y comparar, resulta difícil identificar con claridad cuáles merecen mayor atención.

1.2 Enfoque general del proyecto

El proyecto adopta un enfoque basado en señales observables y medibles. En lugar de asumir que una única variable determina el valor, se parte de la hipótesis de que este emerge de la interacción entre distintas dimensiones. Para capturar esa interacción, la información disponible se organiza en bloques conceptuales coherentes que se analizan de forma conjunta.

A grandes rasgos, el marco integra información relativa a la clasificación tecnológica y su diversidad, la estructura y extensión de la familia de patentes, el historial y estado jurídico, la complejidad organizativa de los actores implicados y determinadas características documentales. Cada uno de estos bloques aporta una perspectiva parcial, pero su combinación permite construir una lectura más rica y operativa del valor potencial de una patente.

1.3 Aportación práctica del trabajo

El principal resultado del proyecto es la transformación de una cartera de patentes en un conjunto de indicadores interpretables que facilitan la priorización de activos. No se trata únicamente de generar un ranking, sino de poder explicar por qué un activo aparece en una determinada posición, qué señales contribuyen a ello y cómo se relacionan entre sí.

La explicabilidad es un elemento clave, ya que las decisiones sobre carteras de patentes suelen justificarse ante perfiles diversos, incluyendo técnicos, juristas y responsables de gestión. El enfoque propuesto busca servir como lenguaje común entre estos perfiles, apoyándose en métricas transparentes y razonadas.

1.4 Alcance y limitaciones

Este trabajo no persigue estimar con precisión absoluta el retorno económico futuro de cada patente. Su alcance es proporcionar una herramienta de apoyo a la decisión que permita ordenar, comparar y analizar carteras de forma coherente, reduciendo el ruido y la arbitrariedad.

En este proyecto no se ha buscado una optimización exhaustiva del modelo con el único objetivo de maximizar la precisión. En el contexto del EPO CodeFest y del pipeline, la prioridad ha sido construir un modelo estable, reproducible y gobernable.

Una optimización agresiva podría haber mejorado ligeramente las métricas, pero a costa de aumentar la complejidad y el riesgo de sobreajuste. Por ello, se ha optado por una regularización explícita que controla la magnitud de los coeficientes y favorece la interpretabilidad, la trazabilidad y la sostenibilidad del sistema.

El resultado es un modelo deliberadamente equilibrado: suficientemente preciso para apoyar la priorización, pero diseñado ante todo para ser mantenible, explicable y robusto en el tiempo.

Las conclusiones deben interpretarse como analíticas y orientativas, condicionadas por la calidad y disponibilidad de los datos. Aun así, el marco propuesto contribuye a mejorar la consistencia, la trazabilidad y la eficiencia en la evaluación de carteras de patentes.

1.5 Estructura del documento

Tras esta introducción, el documento describe el proceso de obtención y preparación de los datos, detallando el pipeline utilizado. A continuación, se presentan los análisis realizados y los resultados obtenidos, así como las decisiones metodológicas que sustentan el enfoque adoptado.

2 Pipeline

El pipeline propuesto sigue una arquitectura reproducible y modular orientada a la gobernanza del ciclo de vida del modelo.

En una primera fase se realiza la preparación del dato, incluyendo imputación robusta de valores ausentes, transformación logarítmica de variables de conteo y normalización mediante standard scaling. El espacio de características se limita a variables numéricas estructurales derivadas del expediente.

Posteriormente, se entrena un modelo base de Ridge Regression, seleccionado por su estabilidad, interpretabilidad y control de varianza. Sobre este modelo se aplica el enfoque de Change-Budget Regularization (L2), que introduce una restricción explícita sobre la magnitud de actualización de los parámetros, garantizando estabilidad temporal y coherencia en escenarios de reentrenamiento.

Regularization by Change Budget: Controlling Model Adaptation via Constrained Optimization

El resultado es un sistema trazable, reproducible y alineado con principios de gobernanza algorítmica.

En el siguiente esquema se muestran los pasos (etapas) del pipeline de generación del modelo para la estimación del ROI de una cartera de patentes.




Figure 1: Pipeline proyecto codefest ROI patente

3 Notebooks

3.1 Proxy de ROI robusto (roi_proxy_v3)

El punto de partida del análisis es una medida inicial de retorno económico, denominada en este trabajo como ROI. Esta magnitud no debe interpretarse como un valor económico real en sentido contable, sino como una **aproximación cuantitativa** construida a partir de señales observables del sistema de patentes. Su función es servir como variable de referencia para el análisis exploratorio y la modelización posterior.

Es importante destacar que esta aproximación no es arbitraria. En un contexto operativo real, el valor de ROI utilizado podría corresponder a una estimación validada o ajustada mediante **criterio experto**, por ejemplo a partir de evaluaciones internas, decisiones estratégicas históricas o análisis previos de explotación. El marco propuesto es compatible con ese escenario, ya que el ROI inicial puede interpretarse como un valor observado, aproximado o consensuado, sobre el cual se aplican ajustes analíticos.

Formalmente, se parte de una primera aproximación al retorno, denotada como $ROI^{(1)}$, que representa el valor base asociado a cada patente:

$$ROI^{(1)} \approx \text{Retorno económico estimado de la patente}$$

Esta magnitud se refina progresivamente incorporando información adicional del sistema, dando lugar a una segunda versión intermedia $ROI^{(2)}$, que integra señales estructurales y contextuales derivadas del análisis exploratorio.

A partir de esta segunda aproximación, el proyecto introduce un **proxy de ROI robusto**, denominado $ROI^{(3)}$, cuyo objetivo es penalizar explícitamente el retorno estimado en función del coste asociado al mantenimiento y la extensión de la patente. Este ajuste permite equilibrar retorno esperado y esfuerzo económico, alineando la métrica con una interpretación más realista del valor neto.

En su forma penalizada, el proxy se define como:

$$ROI^{(3)} = ROI^{(2)} - \lambda \cdot COST$$

donde $COST$ representa una aproximación al coste asociado a la patente y λ actúa como parámetro de penalización que controla la intensidad del ajuste.

Alternativamente, se utiliza una forma normalizada que evita valores negativos y permite una interpretación relativa más estable:

$$ROI^{(3)} = \frac{ROI^{(2)}}{1 + \lambda \cdot COST}$$

Esta formulación normalizada resulta especialmente adecuada para análisis comparativos dentro de una cartera, ya que introduce una penalización suave y continua que preserva el orden relativo entre activos.

El uso de $ROI^{(3)}$ como proxy robusto permite incorporar explícitamente la noción de coste en la evaluación del valor, sin perder trazabilidad ni interpretabilidad. De este modo, la métrica final mantiene coherencia económica, es compatible con validación experta y resulta adecuada como variable objetivo o de referencia en las fases posteriores del proyecto.

El análisis exploratorio constituye la primera fase analítica del proyecto y tiene como finalidad comprender la estructura real del tablón de patentes antes de cualquier modelización. En este punto no se busca todavía explicar ni predecir el valor de una patente, sino identificar patrones, escalas, relaciones y posibles limitaciones de los datos disponibles. Este paso resulta esencial para garantizar que las decisiones posteriores se apoyan en señales consistentes y no en supuestos implícitos.


3.2 Análisis exploratorio de los datos (EDA)

El análisis comienza con una revisión de las variables temporales asociadas a cada patente, en particular las fechas de solicitud, publicación y los intervalos derivados entre hitos relevantes. Estas variables permiten situar cada activo dentro de su ciclo de vida y observar la heterogeneidad temporal del conjunto. En este punto resulta especialmente informativo incluir una gráfica de distribución de antigüedad de las patentes, ya que pone de manifiesto la coexistencia de activos recientes con otros de larga trayectoria, algo habitual en carteras reales y relevante para la interpretación del valor.

A continuación se analizan las variables que actúan como objetivo o como aproximaciones directas al retorno económico, cuando este está disponible. El análisis muestra que estas variables presentan distribuciones altamente asimétricas, con colas largas y una fuerte concentración de valores bajos. Este comportamiento es coherente con fenómenos económicos reales, donde una minoría de activos concentra gran parte del impacto. Una visualización de estas distribuciones, preferiblemente en escala logarítmica, ayuda a comprender por qué serán necesarias transformaciones antes de cualquier modelado y evita interpretaciones engañosas basadas en medias simples.

Como mejora del proyecto se plantea optimizar la estrategia de obtención de datos mediante un esquema de muestreo más aleatorizado y representativo. En la implementación actual, la comprensión y explotación de la API de OPS requirió un esfuerzo considerable, lo que condicionó parcialmente la forma en que se recopilaban las observaciones utilizadas en el modelo.

En futuras iteraciones sería deseable incorporar un mecanismo de extracción más sistemático y estadísticamente equilibrado, que permita garantizar mayor diversidad tecnológica, mejor cobertura temporal y reducción de posibles sesgos derivados del procedimiento de descarga. Esto reforzaría la robustez del entrenamiento y la capacidad de generalización del modelo sobre el conjunto global de patentes.







Figure 3: Distribución Proxies ROI frente a clase (ROI_CLASS)



En la gráfica anterior podemos observar la distribución de valores para el proxy_roi_v3 en comparación con el roi_class.

A partir de la distribución observada de roi_proxy_v3, se aprecia que la mayor parte de las patentes se concentran en un intervalo aproximado entre 3 y 5, con una distribución unimodal relativamente simétrica y algunos valores extremos aislados en la cola derecha.

Aunque el indicador está teóricamente acotado en un rango más amplio, en la muestra analizada los valores efectivos se sitúan mayoritariamente dentro de dicho intervalo central. Valores superiores a 5 pueden considerarse pertenecientes al tramo alto de la distribución, representando expedientes con mayor retorno relativo estimado respecto a la inversión realizada, si bien no constituyen necesariamente el máximo observado.

Los puntos de corte definidos para roi_class_v3 permiten segmentar la distribución en tramos interpretables dentro del marco analítico del modelo.

En la anterior figura observamos la distribución de los valores de proxy_roi_v3 para cada uno de los valores de party_applicant_hype_main.

Para la elección de la variable objetivo se ha utilizado el proxy_roi_v3, al considerarse la aproximación más robusta disponible. Este indicador integra un conjunto de variables estructurales observables (como actividad reciente, tamaño de familia, eventos legales, prioridades o amplitud tecnológica) que actúan como señales cuantificables del valor potencial de una patente.

Conviene señalar que se trata de una variable calculada, diseñada para aproximar el valor real de una patente bajo un marco sistemático y reproducible. No obstante, podría ser sustituida o complementada por un criterio experto en contextos donde se disponga de evaluación cualitativa especializada.

El análisis continúa con las variables relacionadas con los actores implicados en la patente, como el número




Figure 4: Distribución del ROI frente a tipo de solicitud

de solicitantes y de inventores. Estas variables se interpretan como señales indirectas de complejidad organizativa y de esfuerzo inversor. Se observa que la mayoría de las patentes presentan estructuras simples, mientras que un subconjunto reducido muestra una mayor complejidad. Una gráfica de dispersión o una distribución comparativa permite visualizar claramente esta heterogeneidad y explorar su relación preliminar con otras señales de valor.

En el ámbito tecnológico, se estudia la información de clasificación, tanto en términos de número de clases asignadas como de diversidad tecnológica. Este bloque resulta clave para aproximar la complejidad técnica y la amplitud de protección. El análisis exploratorio revela que muchas patentes se concentran en pocas clases, mientras que otras combinan múltiples dominios tecnológicos. Incluir una gráfica que muestre la distribución del número de clases por patente facilita la comprensión de esta variabilidad y su posible papel como señal diferenciadora dentro de la cartera.

Otro eje central del análisis es la familia de patentes y su extensión internacional. Variables como el tamaño de la familia o el número de jurisdicciones reflejan decisiones estratégicas que implican costes sostenidos. El análisis exploratorio pone de manifiesto que la mayoría de las patentes no se extienden ampliamente, mientras que algunas muestran una clara apuesta internacional. Una visualización de la distribución del tamaño de familia resulta especialmente útil para ilustrar esta asimetría y su posible conexión con expectativas de retorno.

El estudio del historial legal y del estado jurídico aporta una dimensión dinámica al análisis. El número de eventos legales y su distribución temporal permiten aproximar el nivel de actividad administrativa y de mantenimiento del activo. El análisis muestra una gran variabilidad en este aspecto, desde patentes con escasa actividad hasta otras con un historial denso. Representar gráficamente el número de eventos legales por patente ayuda a identificar este patrón y refuerza la interpretación de la actividad legal como señal de valor o de vigilancia estratégica.

A partir del historial legal se construyen métricas temporales derivadas, como la frecuencia de eventos o la intensidad administrativa. Estas variables no están directamente disponibles en los datos originales, pero enriquecen de forma significativa el análisis al introducir información dinámica. Una gráfica que relacione estas métricas con la antigüedad o con otras señales clave permite anticipar su utilidad en fases posteriores del proyecto.

Finalmente, el análisis exploratorio aborda características básicas del texto de la patente, como la longitud del título, del resumen y del texto completo cuando está disponible. Aunque estas métricas son simples, actúan como proxies indirectos de densidad informativa y complejidad técnica. El análisis muestra que estas longitudes presentan también distribuciones asimétricas, por lo que una visualización comparativa resulta útil para contextualizar su papel antes de introducir técnicas más avanzadas como los embeddings semánticos.

En conjunto, este análisis exploratorio permite comprender la estructura real del tablón de patentes, identificar transformaciones necesarias, justificar la selección de variables y documentar decisiones analíticas de

forma transparente. Más que producir conclusiones definitivas, esta fase sienta las bases metodológicas para el resto del proyecto y actúa como puente entre la obtención de datos y la modelización explicable del valor de las patentes.

En este notebook, también se presentan contrastes de hipótesis que nos ayudan a seleccionar las mejores features para el modelo, es decir las que verdaderamente expliquen el ROI (variable destino)

3.3 Técnicas de análisis del lenguaje natural (NLP Feature engineering)

El notebook implementa un análisis de de feature engineering basado en procesamiento de lenguaje natural aplicado a los textos descriptivos de las patentes.

En primer lugar, se realiza una limpieza básica del texto (normalización, eliminación de ruido y tokenización). Posteriormente, se extraen representaciones semánticas mediante técnicas vectoriales, generando variables numéricas que capturan información latente del contenido tecnológico.

Estas características se integran en el espacio estructural del modelo, permitiendo complementar las variables jurídicas y procedimentales con señales derivadas del contenido textual.

El resultado es un conjunto de features reproducibles que enriquecen la estimación del proxy_roi_v3 sin introducir complejidad excesiva en el pipeline.

Como evolución del sistema se propone la construcción de un módulo RAG basado en una base vectorial de embeddings generados a partir de todos los textos de las patentes incluyendo título abstract descripción y reivindicaciones. Este repositorio semántico actuaría como un lenguaje universal que permitiría identificar similitudes tecnológicas profundas entre expedientes y detectar patrones asociados históricamente a valores altos o bajos de proxy_roi_v3. La integración de este módulo enriquecería el modelo con señales de similitud semántica y mejoraría la explicabilidad mediante la recuperación de casos comparables capaces de contextualizar y fundamentar la estimación del ROI más allá de los factores estructurales actualmente considerados.

3.4 Selección de características (variables predictoras):

Este notebook implementa la construcción del espacio de variables estructurales utilizadas por el modelo. A partir de los datos crudos del expediente se generan transformaciones robustas orientadas a capturar intensidad jurídica, actividad reciente, tamaño de familia, prioridades y eventos legales.

Se aplican transformaciones logarítmicas sobre variables de conteo para estabilizar varianza y reducir asimetrías, así como combinaciones e interacciones entre variables relevantes con el objetivo de reflejar relaciones no lineales dentro de un marco lineal regularizado. El resultado es un conjunto coherente de features numéricas preparadas para su integración directa en el pipeline de entrenamiento.

El proceso está diseñado para ser reproducible, trazable y alineado con principios de gobernanza del modelo, asegurando consistencia entre entrenamiento, validación y despliegue.

Con el conjunto resultante de características se construye un modelo base de Ridge Regression, que actúa como referencia estable y reproducible para la estimación de proxy_roi_v3. Este modelo permite evaluar la contribución incremental de nuevas variables y mantener coherencia en posteriores fases de optimización y gobernanza.

Las variables predictoras seleccionadas para el modelo son las siguientes:

`is_active_recent`

Variable binaria que indica si la patente ha tenido actividad reciente (por ejemplo, eventos legales o mantenimiento en los últimos años). Actúa como proxy de vigencia económica o interés continuado por parte del titular.




Figure 5: Correlación de variables

log_legal_events_count

Logaritmo del número total de eventos legales asociados a la patente. Captura la intensidad administrativa y estratégica del expediente (oposiciones, validaciones, pagos, etc.), suavizando la asimetría mediante transformación logarítmica.

log_family_size

Logaritmo del tamaño de la familia de patentes. Funciona como indicador de estrategia internacional y expectativa de valor, ya que una mayor extensión territorial suele implicar mayor inversión y relevancia potencial.

novelty_x_breadth

Variable de interacción entre el índice de novedad técnica y la amplitud de las reivindicaciones. Modela el efecto combinado de originalidad y alcance jurídico, aproximando el potencial diferencial de la invención.

novelty_x_family

Interacción entre novedad técnica y tamaño de familia. Refleja el caso en el que una invención altamente novedosa además es protegida internacionalmente, lo que puede amplificar su relevancia estratégica.

log_priority_count

Logaritmo del número de prioridades reivindicadas. Captura complejidad estratégica y posible acumulación de desarrollos previos, estabilizando la escala mediante transformación logarítmica.

log_party_applicant_count

Logaritmo del número de solicitantes o partes asociadas. Actúa como proxy de colaboración, capacidad organizativa o respaldo institucional/empresarial del proyecto tecnológico.

3.5 Dirección del efecto sobre proxy_roi_v3

En el modelo regularizado **proxy_roi_v3**, la relación estimada entre las variables predictoras y el proxy es la siguiente:

log_family_size

Relación directa positiva. A mayor tamaño de familia, mayor valor estimado del proxy.

novelty_x_breadth

Relación directa positiva. Un mayor nivel combinado de novedad técnica y amplitud de reivindicaciones incrementa el proxy.

novelty_x_family

Relación directa positiva. La protección internacional amplifica el efecto de la novedad.

log_legal_events_count

Relación directa positiva. Una mayor intensidad de eventos legales se asocia con mayor valor estimado.

is_active_recent

Relación directa positiva. Si la patente presenta actividad reciente, el proxy aumenta respecto a patentes inactivas.

log_party_applicant_count

Relación directa positiva moderada. Un mayor número de solicitantes tiende a incrementar el proxy, aunque con efecto más limitado.

log_priority_count

Relación directa positiva débil. Un mayor número de prioridades reivindicadas contribuye ligeramente al aumento del proxy.

3.6 Entrenamiento de modelo robustos:

Este notebook amplía el modelo base mediante el entrenamiento de configuraciones más complejas con el objetivo de evaluar estabilidad, capacidad predictiva y sensibilidad a variaciones en los datos. Se comparan

distintos enfoques bajo un marco controlado, manteniendo como referencia el modelo lineal regularizado previamente definido.

El análisis se centra en la robustez del rendimiento, la consistencia de los coeficientes y la estabilidad frente a cambios en el conjunto de entrenamiento. Este proceso permite validar que las mejoras observadas no responden a sobreajuste sino a señales estructurales reales presentes en los datos.

Los resultados refuerzan la elección de un modelo regularizado y gobernable como solución equilibrada entre capacidad explicativa y estabilidad temporal.

Out[19]:

	Adjusted R-Squared	R-Squared	RMSE	Time Taken
Model				
SGDRegressor	0.85	0.85	0.29	0.01
Lars	0.85	0.85	0.29	0.10
LarsCV	0.85	0.85	0.29	0.10
TransformedTargetRegressor	0.85	0.85	0.29	0.01
LassoLarsCV	0.85	0.85	0.29	0.02
LinearRegression	0.85	0.85	0.29	0.01
LassoLarsIC	0.85	0.85	0.29	0.01
Ridge	0.85	0.85	0.29	0.01
RidgeCV	0.85	0.85	0.29	0.01
BayesianRidge	0.85	0.85	0.29	0.01
LassoCV	0.85	0.85	0.29	0.06
ElasticNetCV	0.85	0.85	0.29	0.15
HuberRegressor	0.85	0.85	0.29	0.03
LinearSVR	0.85	0.85	0.30	0.05

Figure 6: Ranking LassyPredict

3.7 Regularización L2 por presupuesto de cambio del modelo finalista:

En este notebook se implementa el núcleo metodológico del proyecto: la aplicación del enfoque Change-Budget Regularization (L2) sobre el modelo base previamente definido. A diferencia de una regularización convencional, este método introduce una restricción explícita sobre la magnitud permitida de actualización de los parámetros respecto a una solución de referencia.

Regularization by Change Budget: Controlling Model Adaptation via Constrained Optimization

El objetivo no es únicamente minimizar el error de predicción, sino controlar la deriva del modelo en sucesivos procesos de reentrenamiento, garantizando estabilidad estructural y coherencia temporal. De este modo, el modelo no solo optimiza rendimiento, sino que incorpora un mecanismo formal de gobernanza algorítmica.

El procedimiento parte de los coeficientes estimados en el modelo base y aplica una optimización restringida que limita el “presupuesto de cambio” total permitido en los parámetros. Esta formulación permite equilibrar

adaptación y estabilidad, reduciendo el riesgo de oscilaciones abruptas ante nuevas observaciones o cambios en la distribución de datos.

Los experimentos realizados muestran que el enfoque mantiene niveles competitivos de rendimiento predictivo mientras mejora significativamente la estabilidad paramétrica, reforzando la interpretabilidad y la trazabilidad del sistema.




Figure 7: Simil del laberinto

Desde una perspectiva conceptual, el enfoque puede entenderse como un recorrido dentro de un espacio de soluciones donde no se permite avanzar de manera arbitraria en cualquier dirección. El modelo parte de una posición de referencia y puede adaptarse, pero únicamente dentro de un “presupuesto de movimiento” previamente definido. En este sentido, la optimización no busca la salida más rápida del laberinto, sino una trayectoria controlada que preserve coherencia estructural y estabilidad temporal.

En la siguiente gráfica se expone la utilidad de la regularización L2 por presupuesto de cambio aplicada al proyecto de estimación de ROI de la patente.




Figure 8: Rendimiento frente a epsilon

La figura muestra la evolución de la correlación de Spearman en función del presupuesto de cambio ε ($\varepsilon = \|\beta - \beta_0\|_1$). Se observa que el rendimiento es máximo cuando el modelo apenas se desvía de la solución de referencia y disminuye progresivamente a medida que se permite un mayor alejamiento.

Este comportamiento indica que la solución base ya captura adecuadamente la estructura del problema y que desviaciones excesivas introducen variabilidad que no mejora el ranking, reforzando la utilidad del enfoque de Change-Budget Regularization como mecanismo de control y estabilidad.

4 API_modelo_ROI – H7 Heptagon Gestor de ciclo de vida del modelo:

La API API_modelo_ROI constituye el componente de producción del proyecto H7 – Heptagon. Se trata de un sistema ligero de gestión y despliegue de modelos inspirado en un enfoque tipo MLflow, diseñado para exponer el modelo ganador como servicio REST en un entorno controlado y reproducible.

4.1 Marco H7 – Heptagon

H7 (Heptagon) representa una arquitectura estructurada basada en siete pilares: datos, características, validación, exportación, despliegue, versionado y monitorización. Este marco garantiza entrenamiento reproducible, despliegue controlado y trazabilidad completa de las valoraciones generadas en el contexto del proyecto.

4.2 Gestión del modelo

La API actúa como un gestor interno de modelos que permite registrar versiones, asociarlas a un contexto lógico y mantener metadatos internos. El artefacto del modelo puede cargarse y registrarse en el arranque o mediante la interfaz de administración, facilitando el control del ciclo de vida y la sustitución segura de modelos en producción.




Figure 9: Registro del modelo

4.3 Exposición REST

El modelo se expone como servicio REST accesible mediante:

```
POST http://localhost:8000/api_h7/<context>
```

5 Epo_client_web Cliente web inferencia modelo:

5.1 Descripción general

La Demo UI de H7 Heptagon es una interfaz web ligera desarrollada en Flask que permite interactuar de forma manual y transparente con el endpoint de inferencia `/api_h7/`. Su finalidad es facilitar la evaluación, experimentación y demostración del modelo dentro del contexto de EPO CodeFest, no su despliegue en producción.

La aplicación actúa como cliente controlado del sistema de gobernanza del modelo H7. Permite introducir variables de entrada desde un formulario web, visualizar el JSON generado, inspeccionar la respuesta del modelo y mantener un pequeño histórico en memoria de las últimas ejecuciones. De este modo se favorece la trazabilidad y la comprensión del comportamiento del sistema.

EPO Model Web Client

REST client for `/api_h7/contexts` endpoints.

Endpoint & Features

Scheme Host Port

Context: Timeout (s):

Effective endpoint: `http://localhost:8000/api_h7/epo_roi`

Is the patent recently active? (0/1) range 0-1

Send empty to omit this feature from the payload.

Log legal events count range 0.0-6.5

Send empty to omit this feature from the payload.

Log family size range 0.0-7.0

Send empty to omit this feature from the payload.

Novelty x breadth range 0.0-1.0

Send empty to omit this feature from the payload.

Novelty x family size range 0.0-7.0

Send empty to omit this feature from the payload.

Log priority count range 0.0-4.0

Send empty to omit this feature from the payload.

Log applicant count range 0.0-5.0

Send empty to omit this feature from the payload.

Tip: you can prefix fields via querystring (eg. `?host=localhost&port=8000&context=epo_roi`).

Output


Payload used

```
{ }
```

Prediction result

```
{ }
```

ROI Interpretation Guide



Interpretation of output variable:

This model version may return ROI values above 1.0. Higher values indicate stronger expected return and stronger commercial potential.

Suggested interpretation bands:

- Low ROI: 0 - 1
- Moderate ROI: 1 - 3
- High ROI: 3 - 5
- Very High ROI: > 5

Last 10 runs

No runs yet.

Last 10 runs

Time	Status	Endpoint	Payload	Result / Error
2026-02-12 22:49:49	OK	<code>http://localhost:8000/api_h7/epo_roi</code>	<pre>{ "context": "epo_roi", "dropped_extra_features": [], "model_sha256": "a667ca910d3da5af399af5146be41750fd7f307ae1893362eeae58fe7f7661", "n_rows": 1, "pred": [5.255849622237322] }</pre>	<pre>200</pre>

Figure 10: Cliente H7 UI


5.2 Propósito dentro del proyecto

La interfaz se concibe como una herramienta de apoyo a la evaluación del modelo de ROI y valoración. Hace explícitos los rangos y reglas de validación de las variables, permitiendo comprobar que las entradas se encuentran dentro de los límites definidos antes de invocar la API.

Los evaluadores pueden probar distintos escenarios sin necesidad de escribir código ni utilizar herramientas externas. El diseño es deliberadamente sencillo y transparente, sin autenticación ni base de datos, manteniendo únicamente un histórico corto en memoria y realizando validaciones previas a la llamada al servicio de inferencia.

5.3 Arquitectura funcional

El flujo comienza con la recogida de variables mediante un formulario web. Posteriormente se validan localmente los rangos definidos para cada característica. Si la validación es correcta, se construye un payload JSON estructurado que se envía al endpoint de inferencia configurado.



La respuesta del modelo se muestra en la interfaz y la ejecución se almacena temporalmente en un historial en memoria. La aplicación opera como cliente explícito del sistema H7 Heptagon, poniendo el foco en la claridad del intercambio de datos, la validación previa y la reproducibilidad de las pruebas manuales.

EPO Model Web Client

REST client for `/api_h7/<context>` endpoints.

Endpoint & Features

Scheme Host Port

Context Timeout (s)

Effective endpoint: `http://localhost:8000/api_h7/modelo1`

Is the patent recently active? (0/1) range 0-1

Send empty to omit this feature from the payload.
Log legal events count range 0.0-6.5

Send empty to omit this feature from the payload.
Log family size range 0.0-7.0

Send empty to omit this feature from the payload.
Novelty × breadth range 0.0-1.0

Send empty to omit this feature from the payload.
Novelty × family size range 0.0-7.0

Send empty to omit this feature from the payload.
Log priority count range 0.0-4.0

Send empty to omit this feature from the payload.
Log applicant count range 0.0-5.0

Output

HTTP 200 Endpoint: `http://localhost:8000/api_h7/modelo1`

Payload used

```
{
  "is_active_recent": [
    1
  ],
  "log_family_size": [
    4.0
  ],
  "log_legal_events_count": [
    3.0
  ],
  "log_party_applicant_count": [
    3.0
  ],
  "log_priority_count": [
    3.0
  ]
}
```

Prediction result

```
{
  "context": "modelo1",
  "dropped_extra_features": [],
  "model_sha256":
    "ae6e7ca910d3da5af399af5146be4175efd7f307aef1093362eeae5
    8fe7f7661",
  "n_rows": 1,
  "pred": [
    4.9006566800344995
  ]
}
```

ROI Interpretation Guide

Main predicted result

Figure 11: Uso del cliente

5.4 Requisitos de ejecución

El entorno requiere Python 3.11 junto con Flask en versión 2.3 o superior y la librería Requests en versión 2.31 o superior.

5.5 Puesta en marcha

La aplicación se ejecuta en un entorno virtual de Python 3.11 con las dependencias instaladas desde el fichero requirements.txt. Una vez iniciada mediante el comando `python app.py`, la interfaz queda disponible en la dirección `http://localhost:5000/`.

Por defecto, el endpoint de inferencia apunta a `http://localhost:8000/api_h7/`, aunque esta configuración puede modificarse desde la propia interfaz para adaptarse a distintos contextos de modelo.

5.6 Contribución al framework H7

La Demo UI complementa el H7 Heptagon Model Governance Framework al materializar una interacción estructurada con el modelo, reforzar los límites de validación de las variables y permitir una evaluación manual reproducible. Su función es evidenciar cómo la invocación del modelo puede integrarse dentro de un marco de gobernanza claro, verificable y controlado.

Siete pilares. Un motor de valoración.

6 Conclusión General

El proyecto H7 Heptagon desarrollado para EPO CodeFest constituye una propuesta integral que abarca modelo, pipeline de entrenamiento, arquitectura de inferencia, marco de gobernanza y cliente de interacción. No se trata únicamente de un sistema de predicción, sino de una solución completa diseñada desde su origen bajo criterios de trazabilidad, estabilidad y reproducibilidad.

En el núcleo del sistema se encuentra el modelo de valoración, construido sobre una base estadística sólida y explicable. A partir de este modelo base se incorpora el enfoque de Regularization by Change Budget, que introduce un mecanismo formal para controlar la magnitud de los cambios respecto a versiones anteriores. Este planteamiento no solo mejora la estabilidad del modelo, sino que permite gestionar su evolución dentro de un marco explícito de gobernanza.

El pipeline garantiza coherencia entre fases de entrenamiento, validación y despliegue. La transformación de variables, la estandarización, la imputación y la generación de artefactos quedan integradas en un flujo reproducible. La contenerización del entorno asegura que el sistema pueda ejecutarse en distintos contextos manteniendo consistencia técnica y operativa.

La API H7 materializa el acceso estructurado al modelo. Define un contrato claro de entrada y salida, permitiendo la invocación controlada del sistema de inferencia. Esta separación entre modelo y capa de servicio refuerza la modularidad y facilita la supervisión del ciclo de vida del modelo.

El cliente H7, desarrollado como Demo UI ligera en Flask, completa el ecosistema proporcionando una interfaz transparente para la evaluación manual. Hace explícitos los rangos de validación, permite inspeccionar el payload JSON y visualizar las respuestas del modelo en un entorno controlado. De este modo, la interacción no queda limitada a desarrolladores, sino que se abre a evaluadores y perfiles no técnicos sin perder rigor.

El conjunto del proyecto articula así cuatro dimensiones complementarias: robustez metodológica, disciplina en el pipeline, claridad arquitectónica y enfoque de gobernanza. Estas dimensiones convergen en una propuesta que equilibra rendimiento predictivo y control institucional.

H7 Heptagon no es únicamente un motor de valoración, sino un marco conceptual y técnico para gestionar modelos de forma responsable. Siete pilares estructuran un sistema pensado para evolucionar sin perder estabilidad, para adaptarse sin comprometer coherencia y para innovar sin renunciar a la transparencia.

En síntesis, el proyecto demuestra que la excelencia técnica, la reproducibilidad y la gobernanza del modelo pueden integrarse desde el diseño inicial como partes inseparables de una misma arquitectura.